

HỆ THỐNG GỢI Ý SẢN PHẨM ĐIỆN TỬ KẾT HỢP MULTIVAE, NEURAL COLLABORATIVE FILTERING VÀ MULTI-LAYER PERCEPTRON

Nguyễn Mai Thiên Quí¹, Võ Thành Duy², Nguyễn Ngọc Hải Anh³, Phan Thanh Thiện³, Nguyễn Lê Quang Trường³

¹Trường Đại học Sư phạm Kỹ thuật TP.HCM

²Khoa Công nghệ Thông tin

Email: 22110216@student.hcmute.edu.vn

Tóm tắt— Sự phát triển nhanh của thương mại điện tử tạo ra lượng dữ liệu người dùng và sản phẩm rất lớn, đòi hỏi các hệ thống gợi ý phải có khả năng cá nhân hóa hiệu quả. Tuy nhiên, nhiều phương pháp recommendation hiện nay vẫn gặp hạn chế như dữ liệu thưa, khó khai thác đầy đủ đặc trưng người dùng – sản phẩm và chưa tối ưu tốt chất lượng xếp hạng gợi ý.

Bài báo đề xuất một hệ thống gợi ý sản phẩm cho tập dữ liệu Amazon Electronics dựa trên mô hình Hybrid Recommendation kết hợp giữa MultiVAE, Neural Collaborative Filtering (NCF), Multi-Layer Perceptron (MLP) và Adaptive Reciprocal Rank Fusion (Adaptive RRF). Hệ thống khai thác đồng thời thông tin tương tác user-item, embedding học được từ MultiVAE và đặc trưng nội dung sản phẩm từ metadata nhằm tăng khả năng biểu diễn dữ liệu và nâng cao mức độ cá nhân hóa recommendation.


Điểm cải tiến của nghiên cứu nằm ở việc áp dụng Pairwise Hard Negative Sampling để lựa chọn các mẫu âm khó thay vì lấy ngẫu nhiên như các phương pháp truyền thống, giúp mô hình học tốt hơn sự khác biệt giữa các sản phẩm phù hợp và không phù hợp. Đồng thời, hàm mất mát kết hợp giữa Bayesian Personalized Ranking (BPR) và Binary Cross-Entropy (BCE) được sử dụng nhằm cải thiện hiệu quả học xếp hạng và nâng cao chất lượng recommendation. Hệ thống đề xuất hướng đến việc tăng hiệu quả gợi ý sản phẩm trong môi trường dữ liệu lớn và thưa, đồng thời cải thiện trải nghiệm người dùng trong các nền tảng thương mại điện tử.

Từ khóa— Recommendation System, MultiVAE, NCF, MLP, Hybrid Recommendation

1 Giới thiệu

Sự phát triển mạnh mẽ của thương mại điện tử làm gia tăng nhanh chóng số lượng sản phẩm và người dùng, dẫn đến tình trạng quá tải thông tin trong quá trình tìm kiếm và lựa chọn sản phẩm. Vì vậy, hệ thống gợi ý (Recommendation System) được sử dụng nhằm cá nhân hóa trải nghiệm người dùng và hỗ trợ đề xuất các sản phẩm phù hợp [4].

Các phương pháp truyền thống như Collaborative Filtering và Matrix Factorization đạt hiệu quả tốt trong nhiều bài toán recommendation, tuy nhiên vẫn tồn tại hạn chế khi xử lý dữ liệu sparse và khó mô hình hóa các mối quan hệ phi tuyến giữa người dùng và sản phẩm [3]. Gần đây, Deep Learning được ứng dụng rộng rãi trong recommendation systems nhờ khả năng học biểu diễn tiềm ẩn và khai thác đặc trưng phức tạp từ dữ liệu [6].



Hình 1: Workflow của hệ thống đề xuất

Nghiên cứu này đề xuất một hệ thống Hybrid Recommendation kết hợp MultiVAE, Neural Collaborative Filtering (NCF) và Multi-Layer Perceptron (MLP). Trong đó, MultiVAE được sử dụng để học latent representation từ ma trận tương tác user-item, NCF khai thác quan hệ phi tuyến dựa trên ID embedding và AE embedding, còn MLP tận dụng đặc trưng nội dung từ metadata sản phẩm. Bên cạnh đó, nghiên cứu áp dụng Pairwise Hard Negative Sampling và hàm mất mát kết hợp BPR-BCE nhằm cải thiện chất lượng học xếp hạng recommendation. Cuối cùng, Adaptive Reciprocal Rank Fusion (Adaptive RRF) được sử dụng để hợp nhất kết quả recommendation theo nhóm mật độ tương tác của người dùng.

2 Phương pháp đề xuất

Hệ thống được xây dựng theo hướng hybrid, kết hợp cả collaborative signal và content signal. Dữ liệu sau tiền xử lý được dùng để huấn luyện MultiVAE, NCF và MLP. Các mô hình con tạo ra danh sách ứng viên riêng, sau đó Adaptive RRF kết hợp các danh sách này để sinh Top-N recommendation.

2.1 Tiền xử lý dữ liệu

Dữ liệu Amazon Electronics bao gồm review và metadata sản phẩm. Các trường văn bản như *title*, *brand*, *category*, *description* và *feature* được chuẩn hóa, sau đó biểu diễn bằng TF-IDF và giảm chiều bằng Truncated SVD để tạo vector đặc trưng cho nhánh MLP.

Đối với dữ liệu review, nghiên cứu loại bỏ các bản ghi thiếu thông tin và giữ lại tương tác mới nhất giữa user và

item. Với metadata, hệ thống chỉ sử dụng các sản phẩm có đầy đủ thông tin mô tả, hình ảnh và giá sản phẩm nhằm đảm bảo chất lượng dữ liệu đầu vào.

Nghiên cứu áp dụng K-core filtering với $k = 10$ nhằm giảm độ sparse và tăng độ ổn định khi huấn luyện. Sau đó, dữ liệu được chia theo chiến lược time-aware split, trong đó các tương tác gần nhất của mỗi user được sử dụng cho validation và test để mô phỏng bài toán recommendation thực tế. Sau tiền xử lý, dữ liệu gồm 733,831 interactions, 47,830 users và 16,461 items.

2.2 Pairwise Hard Negative Sampling

Để cải thiện khả năng học thứ hạng, nghiên cứu sử dụng Pairwise Hard Negative Sampling. Với mỗi positive pair (u, i) , hệ thống sinh các negative item j mà user chưa tương tác. Ngoài negative ngẫu nhiên, mô hình ưu tiên lấy item phổ biến và item cùng danh mục với positive item. Cách này làm tăng độ khó của bài toán, giúp mô hình phân biệt tốt hơn giữa item thực sự phù hợp và item có vẻ liên quan nhưng chưa chắc phù hợp với user.

Chiến lược này đặc biệt quan trọng với dữ liệu sparse vì số lượng tương tác của mỗi user không nhiều. Việc đưa vào hard negatives giúp mô hình học ranking ổn định hơn và giảm khả năng gợi ý các item phổ biến nhưng không phù hợp.

2.3 Mô hình MultiVAE

MultiVAE học phân phối latent của user từ ma trận tương tác user-item [1]. Mô hình không ánh xạ trực tiếp input sang một vector cố định mà học phân phối xác suất của biểu diễn ẩn:

$$q_\phi(z_u|x_u) = \mathcal{N}(\mu_u, \sigma_u^2) \quad (1)$$

Trong đó μ_u và σ_u lần lượt là vector trung bình và độ lệch chuẩn do encoder sinh ra. Để có thể lan truyền gradient qua bước lấy mẫu, mô hình sử dụng reparameterization trick:

$$z_u = \mu_u + \sigma_u \odot \epsilon \quad (2)$$

với $\epsilon \sim \mathcal{N}(0, I)$. Decoder nhận latent vector z_u và tái tạo lại xác suất user tương tác với từng item:

$$\hat{x}_u = f_\theta(z_u) \quad (3)$$

Hàm mất mát gồm reconstruction loss và KL divergence:

$$\mathcal{L}_{VAE} = -E[\log p_\theta(x_u|z_u)] + \beta KL(q_\phi(z_u|x_u)||p(z_u)) \quad (4)$$

Thành phần reconstruction giúp mô hình tái tạo hành vi tương tác của user, trong khi KL divergence điều chỉnh phân phối latent gần với phân phối chuẩn. Nhờ đó, MultiVAE học được biểu diễn người dùng ổn định hơn trên dữ liệu sparse và tạo embedding đầu vào cho các mô hình sau.

2.4 Neural Collaborative Filtering

NCF trong hệ thống không chỉ dùng ID embedding truyền thống mà còn kết hợp embedding trích xuất từ MultiVAE.

Điều này giúp mô hình tận dụng đồng thời thông tin định danh user-item và latent representation đã học từ ma trận tương tác.

Vector đầu vào của user và item được biểu diễn:

$$e_u = [p_u; a_u], \quad e_i = [q_i; a_i] \quad (5)$$

Trong đó p_u, q_i là ID embedding, còn a_u, a_i là AE embedding. Hai vector này được đưa qua các neural tower riêng biệt:

$$z_u = f_u(e_u), \quad z_i = f_i(e_i) \quad (6)$$

Sau đó, điểm tương tác được tính bằng:

$$\hat{y}_{ui} = z_u^T z_i + b_u + b_i \quad (7)$$

Thiết kế này giúp NCF khai thác đồng thời thông tin định danh và latent representation, nhờ đó mạnh hơn NCF truyền thống.

2.5 Multi-Layer Perceptron

MLP khai thác đặc trưng nội dung của sản phẩm từ metadata. Các trường như title, brand, category và description được biểu diễn bằng TF-IDF và giảm chiều bằng Truncated SVD để tạo vector đặc trưng sản phẩm. Ngoài ra, mô hình còn kết hợp các đặc trưng số học như giá bán, số lượt tương tác và điểm đánh giá trung bình.

Nhánh MLP được xây dựng theo kiến trúc two-tower, trong đó một tower ánh xạ embedding người dùng từ MultiVAE và tower còn lại ánh xạ vector đặc trưng sản phẩm về cùng không gian latent:

$$z_u = MLP_{user}(a_u) \quad (8)$$

$$z_i = MLP_{item}(q_i) \quad (9)$$

Điểm recommendation được tính bằng tích vô hướng giữa hai vector:

$$\hat{y}_{ui} = z_u^T z_i + b_u + b_i \quad (10)$$

Kiến trúc này giúp hệ thống kết hợp đồng thời thông tin tương tác và đặc trưng nội dung sản phẩm nhằm cải thiện chất lượng recommendation.

2.6 Hàm mất mát huấn luyện

Các nhánh AE Projector, NCF và MLP được huấn luyện bằng hàm mất mát kết hợp giữa BPR Loss và BCE Loss:

$$L = L_{BPR} + \lambda L_{BCE} \quad (11)$$

$$L_{BPR} = - \sum_{(u,i,j)} \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj}) \quad (12)$$

$$L_{BCE} = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y}) \quad (13)$$

BPR tối ưu thứ hạng giữa positive và negative item, trong khi BCE hỗ trợ phân biệt nhị phân giữa tương tác dương và âm. Việc kết hợp hai loss giúp mô hình vừa học ranking, vừa cải thiện khả năng phân biệt hard negative samples.

2.7 Adaptive Reciprocal Rank Fusion

Sau khi thu được ranking từ các mô hình, hệ thống sử dụng Adaptive RRF để hợp nhất kết quả. RRF không phụ thuộc trực tiếp vào thang điểm dự đoán của từng mô hình mà dựa trên vị trí xếp hạng của item, nhờ đó giảm ảnh hưởng của việc score giữa các mô hình không cùng phân phối.

Điểm RRF của item i trong mô hình m :

$$RRF_m(i) = \frac{1}{k + rank_m(i)} \quad (14)$$

Điểm hybrid cuối cùng:

$$Score(i) = \sum_{m=1}^M w_m(g_u) RRF_m(i) \quad (15)$$

Trong đó $rank_m(i)$ là thứ hạng của item i trong mô hình m , k là hệ số smoothing và $w_m(g_u)$ là trọng số của mô hình m theo nhóm user g_u . Người dùng được chia thành các nhóm sparse, medium và dense dựa trên mật độ tương tác. Với user sparse, hệ thống ưu tiên mô hình học latent representation tốt như MultiVAE. Với user dense, NCF và MLP đóng góp nhiều hơn vì có đủ dữ liệu để học quan hệ phi tuyến.

Tính “adaptive” nằm ở việc trọng số fusion không cố định cho toàn bộ user mà được tìm kiếm trên validation set theo từng nhóm mật độ tương tác. Nhờ đó, Adaptive RRF tận dụng tốt ưu điểm của từng mô hình trong các điều kiện dữ liệu khác nhau.

3 Kết quả và thảo luận

3.1 Quá trình thực nghiệm

Thực nghiệm được thực hiện trên Kaggle với PyTorch và GPU CUDA. Các mô hình được đánh giá bằng Recall@20 và NDCG@20. Ngoài ra, Bootstrap với 500 vòng lặp cho thấy Adaptive RRF cải thiện ổn định hơn so với AE đơn lẻ trên tập test, củng cố tính hiệu quả của phương pháp fusion.

3.2 Kết quả

Bảng 1: Kết quả recommendation trên tập validation

Model	Recall@20	NDCG@20
Popularity	0.0305	0.0111
AE	0.0660	0.0285
NCF	0.0660	0.0283
MLP	0.0488	0.0195
Adaptive RRF	0.0717	0.0309

Kết quả thực nghiệm cho thấy các mô hình học sâu đều cải thiện đáng kể so với phương pháp Popularity baseline. Cụ thể, Popularity chỉ đạt Recall@20 = 0.0305 và NDCG@20 = 0.0111, nghĩa là chỉ khoảng 3.05% người dùng có sản phẩm ground-truth xuất hiện trong top-20 recommendation.

Trong khi đó, AE và NCF đạt Recall@20 = 0.0660, cho thấy khả năng học latent representation và quan hệ phi tuyến giúp cải thiện hiệu quả recommendation. Adaptive RRF đạt

kết quả cao nhất với Recall@20 = 0.0717 và NDCG@20 = 0.0309, tương ứng khoảng 7.17% người dùng có sản phẩm phù hợp xuất hiện trong top-20 recommendation. Đồng thời, NDCG@20 cao hơn cho thấy các sản phẩm phù hợp thường được xếp ở vị trí đầu danh sách gợi ý.

Kết quả này chứng minh việc kết hợp MultiVAE, NCF và MLP bằng Adaptive RRF giúp tận dụng ưu điểm của từng mô hình, từ đó nâng cao khả năng cá nhân hóa và chất lượng recommendation.

3.3 Thảo luận

Kết quả cho thấy mô hình hybrid vượt trội hơn baseline Popularity và các mô hình đơn lẻ. Việc kết hợp AE embedding trong NCF giúp cải thiện khả năng học biểu diễn, trong khi hard negative sampling giúp mô hình phân biệt tốt hơn giữa item phù hợp và item khó. Bootstrap với 500 vòng lặp cho thấy Adaptive RRF ổn định hơn AE đơn lẻ trên nhiều nhóm người dùng, củng cố tính hiệu quả của phương pháp fusion.

4 Kết luận

Bài báo đã đề xuất hệ thống Hybrid Recommendation kết hợp MultiVAE, NCF, MLP và Adaptive RRF cho dữ liệu Amazon Electronics. Kết quả cho thấy phương pháp đề xuất cải thiện Recall@20 và NDCG@20 so với các mô hình đơn lẻ và baseline Popularity. Trong tương lai, nghiên cứu có thể mở rộng theo hướng recommendation thời gian thực và ứng dụng Transformer trong recommendation systems.

Tài liệu

- [1] Liang D., Krishnan R., Hoffman M., Jebara T., “Variational Autoencoders for Collaborative Filtering,” WWW Conference, 2018.
- [2] He X., Liao L., Zhang H., Nie L., Hu X., Chua T., “Neural Collaborative Filtering,” WWW Conference, 2017.
- [3] Koren Y., Bell R., Volinsky C., “Matrix Factorization Techniques for Recommender Systems,” IEEE Computer, 2009.
- [4] Ricci F., Rokach L., Shapira B., “Recommender Systems Handbook,” Springer, 2022.
- [5] Rendle S., “BPR: Bayesian Personalized Ranking from Implicit Feedback,” UAI Conference, 2009.
- [6] Zhang S., Yao L., Sun A., Tay Y., “Deep Learning Based Recommender System: A Survey,” ACM Computing Surveys, 2019.
- [7] Sedhain S., Menon A., Sanner S., Xie L., “AutoRec: Autoencoders Meet Collaborative Filtering,” WWW Conference, 2015.
- [8] Kang W., McAuley J., “Self-Attentive Sequential Recommendation,” ICDM Conference, 2018.