

HỆ THỐNG GỢI Ý SẢN PHẨM ĐIỆN TỬ KẾT HỢP MULTIVAE, NEURAL COLLABORATIVE FILTERING VÀ MULTI-LAYER PERCEPTRON

Nguyễn Mai Thiên Quý¹, Võ Thành Duy², Nguyễn Ngọc Hải Anh³, Phan Thanh Thiện³, Nguyễn Lê Quang Trường³

¹Trường Đại học Sư phạm Kỹ thuật TP.HCM

²Khoa Công nghệ Thông tin


Email: 22110216@student.hcmute.edu.vn

Tóm tắt— Sự phát triển nhanh của thương mại điện tử tạo ra lượng dữ liệu người dùng và sản phẩm rất lớn, đòi hỏi các hệ thống gợi ý phải cá nhân hóa hiệu quả. Tuy nhiên, dữ liệu thưa, khó khai thác đầy đủ đặc trưng user-item và chất lượng xếp hạng vẫn là các thách thức lớn.

Bài báo đề xuất hệ thống gợi ý sản phẩm cho tập Amazon Electronics dựa trên mô hình Hybrid Recommendation kết hợp MultiVAE, Neural Collaborative Filtering (NCF), Multi-Layer Perceptron (MLP) và Adaptive Reciprocal Rank Fusion (Adaptive RRF). Hệ thống khai thác đồng thời thông tin tương tác, embedding từ MultiVAE và đặc trưng nội dung sản phẩm từ metadata nhằm nâng cao khả năng cá nhân hóa recommendation.

Điểm cải tiến của nghiên cứu nằm ở Pairwise Hard Negative Sampling, giúp lựa chọn các mẫu âm khó thay vì lấy ngẫu nhiên. Đồng thời, hàm mất mát kết hợp Bayesian Personalized Ranking (BPR) và Binary Cross-Entropy (BCE) được sử dụng để cải thiện học xếp hạng và chất lượng recommendation.

Từ khóa— Recommendation System, MultiVAE, NCF, MLP, Hybrid Recommendation



Hình 1: Workflow của hệ thống đề xuất

2 Phương pháp đề xuất

Hệ thống được xây dựng theo hướng hybrid, kết hợp collaborative signal và content signal. Dữ liệu sau tiền xử lý được dùng để huấn luyện MultiVAE, NCF và MLP. Các mô hình con tạo ra danh sách ứng viên riêng, sau đó Adaptive RRF kết hợp các danh sách này để sinh Top-N recommendation.

1 Giới thiệu

Sự phát triển của thương mại điện tử làm gia tăng số lượng sản phẩm và người dùng, dẫn đến tình trạng quá tải thông tin. Vì vậy, hệ thống gợi ý được sử dụng nhằm cá nhân hóa trải nghiệm và hỗ trợ đề xuất sản phẩm phù hợp [4].

Các phương pháp Collaborative Filtering và Matrix Factorization đạt hiệu quả trong nhiều bài toán recommendation, nhưng còn hạn chế khi xử lý dữ liệu sparse và các quan hệ phi tuyến giữa người dùng và sản phẩm [3]. Deep Learning được ứng dụng rộng rãi nhờ khả năng học biểu diễn tiềm ẩn và khai thác đặc trưng phức tạp từ dữ liệu [6].

Nghiên cứu này đề xuất hệ thống Hybrid Recommendation kết hợp MultiVAE, NCF và MLP. MultiVAE học latent representation từ ma trận tương tác user-item, NCF khai thác quan hệ phi tuyến dựa trên ID embedding và AE embedding, còn MLP tận dụng đặc trưng nội dung từ metadata sản phẩm. Pairwise Hard Negative Sampling, BPR-BCE và Adaptive RRF được sử dụng để cải thiện chất lượng học xếp hạng và hợp nhất kết quả recommendation.

2.1 Tiền xử lý dữ liệu

Dữ liệu Amazon Electronics bao gồm review và metadata sản phẩm. Các trường văn bản như *title*, *brand*, *category*, *description* và *feature* được chuẩn hóa, biểu diễn bằng TF-IDF và giảm chiều bằng Truncated SVD để tạo vector đặc trưng cho nhánh MLP.

Đối với review, nghiên cứu loại bỏ bản ghi thiếu thông tin và giữ lại tương tác mới nhất giữa user và item. Nghiên cứu áp dụng K-core filtering với $k = 10$ nhằm giảm độ sparse, sau đó chia dữ liệu theo chiến lược time-aware split. Sau tiền xử lý, dữ liệu gồm 733,831 interactions, 47,830 users và 16,461 items.

2.2 Pairwise Hard Negative Sampling

Để cải thiện khả năng học thứ hạng, nghiên cứu sử dụng Pairwise Hard Negative Sampling. Với mỗi positive pair (u, i) , hệ thống sinh negative item j mà user chưa tương tác. Ngoài negative ngẫu nhiên, mô hình ưu tiên lấy item phổ biến và item cùng danh mục với positive item. Cách này giúp mô hình phân biệt tốt hơn giữa item phù hợp và item có vẻ liên quan nhưng chưa chắc phù hợp với user [5].

2.3 Mô hình MultiVAE

MultiVAE học phân phối latent của user từ ma trận tương tác user-item [1]. Mô hình học phân phối xác suất của biểu diễn ẩn [1]:

$$q_\phi(z_u|x_u) = \mathcal{N}(\mu_u, \sigma_u^2)$$

Để lan truyền gradient qua bước lấy mẫu, mô hình sử dụng reparameterization trick [1]:

$$z_u = \mu_u + \sigma_u \odot \epsilon$$

Decoder nhận latent vector z_u và tái tạo lại xác suất user tương tác với từng item [1]:

$$\hat{x}_u = f_\theta(z_u)$$

Hàm mất mát gồm reconstruction loss và KL divergence [1]:

$$\mathcal{L}_{VAE} = -E[\log p_\theta(x_u|z_u)] + \beta KL(q_\phi(z_u|x_u)||p(z_u))$$

MultiVAE giúp học biểu diễn người dùng ổn định hơn trên dữ liệu sparse và tạo embedding đầu vào cho các mô hình sau.

2.4 Neural Collaborative Filtering

NCF trong hệ thống không chỉ dùng ID embedding truyền thống mà còn kết hợp embedding trích xuất từ MultiVAE, giúp tận dụng đồng thời thông tin định danh user-item và latent representation [2].

Vector đầu vào của user và item được biểu diễn dựa trên kiến trúc NCF và phần mở rộng embedding trong hệ thống đề xuất [2]:

$$e_u = [p_u; a_u], \quad e_i = [q_i; a_i]$$

Trong đó p_u, q_i là ID embedding, còn a_u, a_i là AE embedding. Hai vector này được đưa qua các neural tower riêng biệt [2]:

$$z_u = f_u(e_u), \quad z_i = f_i(e_i)$$

Điểm tương tác được tính bằng [2]:

$$\hat{y}_{ui} = z_u^T z_i + b_u + b_i$$

2.5 Multi-Layer Perceptron

MLP khai thác đặc trưng nội dung của sản phẩm từ metadata. Các trường như title, brand, category và description được biểu diễn bằng TF-IDF và giảm chiều bằng Truncated SVD. Ngoài ra, mô hình còn kết hợp các đặc trưng số học như giá bán, số lượt tương tác và điểm đánh giá trung bình [6].

Nhánh MLP được xây dựng theo kiến trúc two-tower, trong đó một tower ánh xạ embedding người dùng từ MultiVAE và tower còn lại ánh xạ vector đặc trưng sản phẩm về cùng không gian latent [6]:

$$z_u = MLP_{user}(a_u), \quad z_i = MLP_{item}(c_i)$$

Điểm recommendation được tính bằng tích vô hướng giữa hai vector [6]:

$$\hat{y}_{ui} = z_u^T z_i + b_u + b_i$$

2.6 Hàm mất mát huấn luyện

Các nhánh AE Projector, NCF và MLP được huấn luyện bằng hàm mất mát kết hợp giữa BPR Loss và BCE Loss cho bài toán implicit feedback [5]:

$$L = L_{BPR} + \lambda L_{BCE}$$

BPR Loss tối ưu thứ hạng giữa positive item và negative item [5]:

$$L_{BPR} = - \sum_{(u,i,j)} \ln \sigma(\hat{y}_{ui} - \hat{y}_{uj})$$

BCE Loss hỗ trợ phân biệt nhị phân giữa tương tác dương và âm:

$$L_{BCE} = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y})$$

Việc kết hợp hai loss giúp mô hình vừa học ranking, vừa cải thiện khả năng phân biệt hard negative samples.

2.7 Adaptive Reciprocal Rank Fusion

Sau khi thu được ranking từ các mô hình, hệ thống sử dụng Adaptive RRF để hợp nhất kết quả dựa trên nguyên lý Reciprocal Rank Fusion [9]. RRF dựa trên vị trí xếp hạng của item, nhờ đó giảm ảnh hưởng của việc score giữa các mô hình không cùng phân phối.

Điểm RRF của item i trong mô hình m được tính theo công thức Reciprocal Rank Fusion [9]:

$$RRF_m(i) = \frac{1}{k + rank_m(i)}$$

Điểm hybrid cuối cùng được tính bằng cách kết hợp điểm RRF của các mô hình với trọng số theo nhóm user:

$$Score(i) = \sum_{m=1}^M w_m(g_u) RRF_m(i)$$

Trong đó $rank_m(i)$ là thứ hạng của item i , k là hệ số smoothing và $w_m(g_u)$ là trọng số của mô hình m theo nhóm user g_u . Người dùng được chia thành các nhóm sparse, medium và dense dựa trên mật độ tương tác. Tính “adaptive” nằm ở việc trọng số fusion được tìm kiếm trên validation set theo từng nhóm mật độ tương tác.

3 Kết quả và thảo luận

3.1 Quá trình thực nghiệm

Thực nghiệm được thực hiện trên Kaggle với PyTorch và GPU CUDA. Các mô hình được đánh giá bằng Recall@20 và NDCG@20. Bootstrap với 500 vòng lặp cho thấy Adaptive RRF cải thiện ổn định hơn so với AE đơn lẻ trên tập test.

3.2 Kết quả

Bảng 1: Kết quả recommendation trên tập validation

Model	Recall@20	NDCG@20
Popularity	0.0305	0.0111
AE	0.0660	0.0285
NCF	0.0660	0.0283
MLP	0.0488	0.0195
Adaptive RRF	0.0717	0.0309

Kết quả thực nghiệm cho thấy các mô hình học sâu đều cải thiện đáng kể so với Popularity baseline. Popularity chỉ đạt $\text{Recall@20} = 0.0305$ và $\text{NDCG@20} = 0.0111$, nghĩa là khoảng 3.05% người dùng có sản phẩm ground-truth xuất hiện trong top-20 recommendation.

AE và NCF đạt $\text{Recall@20} = 0.0660$, cho thấy latent representation và quan hệ phi tuyến giúp cải thiện hiệu quả recommendation. Adaptive RRF đạt kết quả cao nhất với $\text{Recall@20} = 0.0717$ và $\text{NDCG@20} = 0.0309$, tương ứng khoảng 7.17% người dùng có sản phẩm phù hợp xuất hiện trong top-20 recommendation.

3.3 Thảo luận

Kết quả cho thấy mô hình hybrid vượt trội hơn baseline Popularity và các mô hình đơn lẻ. Việc kết hợp AE embedding trong NCF giúp cải thiện khả năng học biểu diễn, trong khi hard negative sampling giúp mô hình phân biệt tốt hơn giữa item phù hợp và item khó [5]. Adaptive RRF ổn định hơn AE đơn lẻ trên tập test, củng cố hiệu quả của phương pháp fusion.

4 Kết luận

Bài báo đã đề xuất hệ thống Hybrid Recommendation kết hợp MultiVAE, NCF, MLP và Adaptive RRF cho dữ liệu Amazon Electronics. Kết quả cho thấy phương pháp đề xuất cải thiện Recall@20 và NDCG@20 so với các mô hình đơn lẻ và baseline Popularity. Trong tương lai, nghiên cứu có thể mở rộng theo hướng recommendation thời gian thực và ứng dụng Transformer trong recommendation systems.

Tài liệu

- [1] Liang D., Krishnan R., Hoffman M., Jebara T., "Variational Autoencoders for Collaborative Filtering," WWW Conference, 2018.
- [2] He X., Liao L., Zhang H., Nie L., Hu X., Chua T., "Neural Collaborative Filtering," WWW Conference, 2017.
- [3] Koren Y., Bell R., Volinsky C., "Matrix Factorization Techniques for Recommender Systems," IEEE Computer, 2009.
- [4] Ricci F., Rokach L., Shapira B., "Recommender Systems Handbook," Springer, 2022.
- [5] Rendle S., "BPR: Bayesian Personalized Ranking from Implicit Feedback," UAI Conference, 2009.

- [6] Zhang S., Yao L., Sun A., Tay Y., "Deep Learning Based Recommender System: A Survey," ACM Computing Surveys, 2019.
- [7] Sedhain S., Menon A., Sanner S., Xie L., "AutoRec: Autoencoders Meet Collaborative Filtering," WWW Conference, 2015.
- [8] Kang W., McAuley J., "Self-Attentive Sequential Recommendation," ICDM Conference, 2018.
- [9] Cormack G., Clarke C., Buettcher S., "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods," SIGIR Conference, 2009.